

语义分割学习笔记

导航

1 前言	3
2 准备知识	3
2.1 数据集	3
2.1.1 室内场景 (ADE20K)	3
2.1.2 室外场景 (Cityscapes)	3
2.2 注意力机制	3
2.3 自注意力机制	4
2.3.1 为什么使用 LN 而不是 BN, dropout 与 LN 同时使用时, 有什么特殊操作?	4
2.3.2 为什么要基于学习的词向量空间?	5
2.3.3 可学习的位置编码?	5
2.4 多头注意力机制	5
3 从语义分割的几个桎梏说起	5
3.1 PSPNet	5
3.2 Deeplab 系列	6
3.3 HRNet	6
3.4 ResNeSt	7
3.5 DDRNet	8
4 Transformer, 它来了	9
4.1 UperNet	9
4.2 Vision Transformer	10
4.2.1 简介	10
4.2.2 ViT 的结构	11
4.3 ViT+Adapter	13
4.4 Object Contextual Representation, OCR	14
4.5 SETR	15
4.5.1 Decoder 设计	16
4.6 Mask2Former	17

- 4.7 Swin Transformer 17
 - 4.7.1 Patch Merging 18
 - 4.7.2 Shifted window 19
 - 4.7.3 Swin Transformer Block 20
 - 4.7.4 消融实验 20
 - 4.7.5 Patch Diversification 21
- 4.8 SwinV2 22
- 4.9 BeiT 22
 - 4.9.1 Blockwise mask 23
 - 4.9.2 MASK AutoEncoder, MAE 24
- 4.10 BeiTV2 24
 - 4.10.1 向量化知识蒸馏, VQ-KD 25
 - 4.10.2 块聚合 25
- 5 半监督学习 26
 - 5.1 Mean Teacher 26

1 前言

以下是在学习基于深度学习方法实现语义分割的过程中，总结的论文、学习报告、博客等等，以及针对部分问题提出的个人看法，特此记录！

2 准备知识

2.1 数据集

2.1.1 室内场景 (ADE20K)

- 基本介绍：2016 年，MIT 开放的场景理解数据集，可用于实例分割、语义分割和零部件分割
- 数据构成：共 27574 张图（训练集 25574 张；验证集 2000 张；测试集未发布），3688 个物体类别，707868 个对象；193238 个零部件

Cityscapes 是一个大型数据库，。它为 30 个类提供语义、实例和密集像素注释，这些类分为 8 个类别（平面、人、车辆、建筑、对象、自然、天空和虚空）。该数据集由大约 5000 张精细注释图像和 20000 张粗标图像组成。在几个月、白天和良好的天气条件下，在 50 个城市捕获了数据。它最初是作为视频录制的，因此手动选择帧以具有以下功能：大量动态对象、不同的场景布局 and 不同的背景。

2.1.2 室外场景 (Cityscapes)

- 基本介绍：专注于对城市街景的语义理解。白天场景，天气良好的 50 个城市
- 数据构成：精标数据 5000 张（训练集 3475 张；测试集 1525 张），粗标数据 20000 张，30 个类（8 个大类：地面、人、车辆、建筑、object、自然、天空和 void）

2.2 注意力机制

简单的说，注意力机制描述了序列元素的加权平均值，其权重是根据输入的 query 和元素的 key 进行动态计算的。具体地，在注意力机制中，有 4 个概念需要明确

- Query: Query（查询）是一个特征向量，描述我们在序列中寻找什么，即我们可能想要注意什么
- Keys: 每个输入元素有一个键，它也是一个特征向量。该特征向量粗略地描述了该元素“提供”什么，或者它何时可能很重要。键的设计应该使得我们可以根据 Query 来识别我们想要关注的元素
- Values: 每个输入元素，我们还有一个值向量。这个向量就是我们想要平均的向量
- Score function: 评分函数，为了对想要关注的元素进行评分，需要指定一个评分函数 f 该函数将查询和键作为输入，并输出查询-键对的得分/注意力权重。它通常通过简单的相似性度量来实现，例如点积或 MLP。

由此，权重通过 softmax 函数计算：

$$\alpha_i = \frac{\exp(f_{\text{attn}}(\text{Key}_i, \text{Query}))}{\sum_j \exp(f_{\text{attn}}(\text{key}_j, \text{query}))}, \text{out} = \sum_i \alpha_i \text{value}_i \quad (1)$$

2.3 自注意力机制




图 1: 自注意力机制流程图

自注意力背后的核心概念是缩放点积注意力 (Scaled Dot Product Attention)。目标是建立一种注意力机制，序列中的任何元素都可以关注任何其他元素，同时仍能高效计算。点积注意力将一组查询 Q ，键 K 和值 V (三者矩阵尺寸为 $T * d$ ， T 为序列长度， d 为查询、键或值的维度)。点积注意力的计算方法如下：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2)$$

$\frac{1}{d_k}$ 是因为 $d_k = 512$ 较大，点积较大，影响梯度

2.3.1 为什么使用 LN 而不是 BN，dropout 与 LN 同时使用时，有什么特殊操作？

BN 是全局计算均值和反差，LN 是自身计算均值和方差，只要是因为训练数据为序列时，长度变化比较大

2.3.2 为什么要基于学习的词向量空间？

2.3.3 可学习的位置编码？

2.4 多头注意力机制

类似卷积网络多通道。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (3)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (4)$$

其中 $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$

3 从语义分割的几个桎梏说起

- 归纳偏置：基于先验信息，只需要相对少的数据就可以学习一个比较好的模型
 - 局部性，即图片上相邻的区域具有相似的特征；
 - 平移不变性 $f(g(x)) = g(f(x))$ ，其中 g 代表卷积操作， f 代表平移操作
- 数据：
 - 现实的数据往往缺乏标签
 - 数据标注需要很大的资源投入——烧很多的钱
 - 很多任务难以获取真实标签
- 泛化性
 - 辛辛苦苦训练好了一个模型，换了一个场景后，模型的性能出现很大下滑
 - 按传统方式解决这一问题，是将新场景的数据采集一遍，然后标注好，再重新训练。这工作量一言难尽。。。

3.1 PSPNet

psp 的核心师采用了步长不同、pool_size 不同的平均池化层进行池化，然后将池化的结果重新 resize 到一个 hw 上后，再 concatenate




Figure 3. Overview of our proposed PSPNet. Given an input image (a), we first use CNN to get the feature map of the last convolutional layer (b), then a pyramid parsing module is applied to harvest different sub-region representations, followed by upsampling and concatenation layers to form the final feature representation, which carries both local and global context information in (c). Finally, the representation is fed into a convolution layer to get the final per-pixel prediction (d).

图 2: PSPNet 网络结构

3.2 Deeplab 系列

提醒： DCNN 存在的问题！

下采样可以增大感受野，但是会导致分辨率降低，丢失细节信息

创新点：

- 引入空洞卷积，减少池化操作
- 引入概率模型（CRF），解决 poor localization property

提醒： CRF 介绍

能量函数：

$$E(x) = \sum_i \sigma(x_i) + \sum_{ij} \sigma_{ij}(x_i, x_j) \quad (5)$$

其中， σ_i 为一元势函数，定义为 $\sigma_i(x_i) = -\log P(x_i)$ 。 $P(x_i)$ 为像素 i 的预测概率

CNN 的方法本质上存在着一个巨大的桎梏，就是图像初始阶段输入到网络之时，CNN 的卷积核不会太大，所以模型只能利用局部信息理解输入图像，难免有些一叶障目

3.3 HRNet

理论参考：[Link](#)

HRNet(图4) 通过并行多个分辨率分支以及不同分支之间的信息交互，获取强语义信息 & 精准位置信息。而在此之前几乎所有的网络(图3) 都是通过下采样得到强语义信息，再上采样恢复高分辨率信息，导致大量的有效信息会在不断的上下采样过程中丢失。




图 3: 由低分辨率恢复到高分辨率的网络结构图




Fig. 2. An example of a high-resolution network. Only the main body is illustrated, and the stem (two stride-2 3×3 convolutions) is not included. There are four stages. The 1st stage consists of high-resolution convolutions. The 2nd (3rd, 4th) stage repeats two-resolution (three-resolution, four-resolution) blocks. The detail is given in Section 3.

图 4: HRNet 网络结构图




Fig. 4. (a) HRNetV1: only output the representation from the high-resolution convolution stream. (b) HRNetV2: Concatenate the (upsampled) representations that are from all the resolutions (the subsequent 1×1 convolution is not shown for clarity). (c) HRNetV2p: form a feature pyramid from the representation by HRNetV2. The four-resolution representations at the bottom in each sub-figure are outputted from the network in Figure 2, and the gray box indicates how the output representation is obtained from the input four-resolution representations.

图 5: HRNet 变体

图 (a)HRNetV1 只有高分辨率输出，一般用于姿态估计；图 (b)HRNetV2 把低分辨率的上采样后与高分辨率进行拼接 concatenate 操作，再用一个 1×1 卷积，一般用于语义分割；图 (c)HRNetV2P 是将图 (b) 的输出下采样，一般用于目标检测

3.4 ResNeSt

将通道维度的注意力机制扩展到特征图组表示，可以使用统一的 CNN 操作符进行模块化和加速




Figure 2: Comparing our ResNeSt block with SE-Net [28] and SK-Net [36]. A detailed view of Split-Attention unit is shown in Figure 3. For simplicity, we show ResNeSt block in cardinality-major view (the featuremap groups with same cardinal group index reside next to each other). We use radix-major in the real implementation, which can be modularized and accelerated by group convolution and standard CNN layers (see supplementary material).




Figure 3: Split-Attention within a cardinal group. For easy visualization in the figure, we use $c = C/K$ in this figure.

3.5 DDRNet

- **应用场景：**高分辨率图像实时语义分割
- **动机：**
- **创新点：**1. 使用两个分辨率不同的分支，一个用于生成高分辨率的特征图，另一个通过多次降采样提取丰富的语义信息，并在两个分支之间建立多个双边连接，实现高效信息融合；2. 提出一个新的多尺度模块 DAPPM **标签：**一个效果还不错的实时语义分割网络

1. 深度双分辨率网络

2. DAPPM 作者认为, 仅使用一个 3×3 卷积或 1×1 卷积将所有的多尺度上下文信息融合在一起是不够的。所以采用类似 **Res2Net** 的结构, 首先对特征图进行上采样 (灰色块), 然后使用更多的 3×3 卷积, 以层次残差 hierarchical-residual 的方式融合不同尺度的上下文信息 (紫色块)。最后将所有得到的特征 concatenate 并使用一个 1×1 卷积压缩。此外, 为了便于优化, 还添加了一个 1×1 卷积映射作为 shortcut。

4 Transformer, 它来了

针对 CNN 模型不能在一开始就从全局理解输入图像的问题, 基于 Transformer 的方案, 是将输入的图像 Token 化, 然后利用自注意力机制使得模型一开始就以全局的角度去理解图片。

提醒: CNN 和 Transformer 区别总结

- CNN 局部感受野, 如果要和很远的信息发生联系, 模型就要做深; 而 Transformer 是直接全局联系
- Transformer 需要更多的参数, 需要强大的算力支持
- NLP 也用 Transformer, 因此 CV 可以和 NLP 结合起来做多模态
- 纯 CV 场景还是 CNN, 快且便宜

4.1 UperNet

Multi-task 任务




Fig. 4. UPerNet framework for Unified Perceptual Parsing. Top-left: The Feature Pyramid Network (FPN) [31] with a Pyramid Pooling Module (PPM) [16] appended on the last layer of the back-bone network before feeding it into the top-down branch in FPN. Top-right: We use features at various semantic levels. Scene head is attached on the feature map directly after the PPM since image-level information is more suitable for scene classification. Object and part heads are attached on the feature map fused by all the layers put out by FPN. Material head is attached on the feature map in FPN with the highest resolution. Texture head is attached on the Res-2 block in ResNet [1], and fine-tuned after the whole network finishes training on other tasks. Bottom: The illustrations of different heads. Details can be found in Section 3.

4.2 Vision Transformer

4.2.1 简介

早在 2020 年 ICLR, 发表过一篇类似的文章, 在 CIFRA-10 数据集上做 2×2 的 patch 操作

VIT 的核心结论是, 当拥有足够多的数据进行预训练的时候, ViT 的表现就会超过 CNN, 突破 transformer 缺少归纳偏置的限制, 可以在下游任务中获得较好的迁移效果




Figure 3: Transfer to ImageNet. While large ViT models perform worse than BiT ResNets (shaded area) when pre-trained on small datasets, they shine when pre-trained on larger datasets. Similarly, larger ViT variants overtake smaller ones as the dataset grows.




Figure 4: Linear few-shot evaluation on ImageNet versus pre-training size. ResNets perform better with smaller pre-training datasets but plateau sooner than ViT, which performs better with larger pre-training. ViT-b is ViT-B with all hidden dimensions halved.

4.2.2 ViT 的结构

ViT 将输入图片分为多个 patch (16×16), 再将每个 patch 投影为固定长度的向量送入 Transformer **【降低序列长度】**, 后续 encoder 的操作和原始 Transformer 中完全相同。但是因为对图片分类, 因此在输入序列中加入一个特殊的 token, 该 token 对应的输出即为最后的类别预测




图 6: ViT 结构图

按照上面的流程图, 一个 ViT block 可以分为以下几个步骤

- patch embedding: 例如输入图片大小为 224×224 , 将图片分为固定大小的 patch, patch 大小为 16×16 , 则每张图像会生成 $224 \times 224 / 16 \times 16 = 196$ 个 patch, 即输入序列长度为 196, 每个 patch 维度 $16 \times 16 \times 3 = 768$, 线性投射层的维度为 $768 \times N$ ($N = 768$), 因此输入通过线性投射层之后的维度依然为 196×768 , 即一共有 196 个 token, 每个 token 的维度是 768。这里还需要加上一个特殊字符 cls, 因此最终的维度是 197×768 。到目前为止, 已经通过 patch embedding 将一个视觉问题转化为了一个 seq2seq 问题【**也可以考虑使用 CNN 提取输入序列**】
- positional encoding: ViT 同样需要加入位置编码, 位置编码可以理解为一张表, 表一共有 N 行, N 的大小和输入序列长度相同, 每一行代表一个向量, 向量的维度和输入序列 embedding 的维度相同 $= 768$ 。**注意:** 位置编码的操作是 sum, 而不是 concat。加入位置编码信息之后, 维度依然是 197×768
- LN/multi-head attention/LN: LN 输出维度依然是 197×768 。多头自注意力时, 先将输入映射到 q, k, v , 如果只有一个头, qkv 的维度都是 197×768 , 如果有 12 个头, 则 qkv 的维度是 197×64 , 一共有 12 组 qkv , 最后再将 12 组 qkv 的输出拼接起来, 输出维度是 197×768 , 然后在过一层 LN, 维度依然是 197×768
- MLP: 将维度放大再缩小回去, 197×768 放大为 197×3072 , 再缩小变为 197×768

一个 block 之后维度依然和输入相同, 都是 197×768 , 因此可以堆叠多个 block。最后会将特殊字符 cls 对应的输出作为 encoder 的最终输出【**另一种做法是不加 cls 字符, 对所有的 tokens 的输出做一个平均**】

提醒： 关于 positional encoding

- 不使用位置编码：模型的性能损失也没有特别大。原因可能是因为 ViT 是作用在 image patch 上的，而不是 image pixel，对网络来说这些 patch 之间的相对位置信息容易理解一些
- 1-D 位置编码：例如 $3 \times 3 = 9$ 个 patch，patch 编码为 1 到 9
- 2-D 位置编码：patch 编码为 11, 12, 13, 21, 22, 23, 31, 32, 33，即同时考虑 X 和 Y 轴的信息，每个轴的编码维度是 $D/2$
- 相对位置编码

Pos. Emb.	Default/Stem	Every Layer	Every Layer-Shared
No Pos. Emb.	0.61382	N/A	N/A
1-D Pos. Emb.	0.64206	0.63964	0.64292
2-D Pos. Emb.	0.64001	0.64046	0.64022
Rel. Pos. Emb.	0.64032	N/A	N/A

Table 8: Results of the ablation study on positional embeddings with ViT-B/16 model evaluated on ImageNet 5-shot linear.

实际实验结果表明，不管使用哪种位置编码方式，模型的精度都很接近。

使用位置编码的局限性是：当图像变大，相应的图像块的数量变大，需要对位置编码进行插值处理，在一定程度上会影响模型效果。

4.3 ViT+Adapter




Figure 4: **Overall architecture of ViT-Adapter.** (a) The ViT, whose encoder layers are divided into N (usually $N = 4$) equal blocks for feature interaction. (b) Our ViT-Adapter, which contains three key designs, including (c) a spatial prior module for modeling local spatial contexts from the input image, (d) a spatial feature injector for introducing spatial priors into ViT, and (e) a multi-scale feature extractor for reorganizing multi-scale features from the single-scale features of ViT.

4.4 Object Contextual Representation, OCR

通过像素和所有类别的相关性，来加强所属类别的表示。类似于自注意力机制它和 PSPNet3.1的区别是，前者学习的是类别区域之间的关系，而后者学习的是周边像素的关系




Fig. 2: Illustrating the multi-scale context with the ASPP as an example and the OCR context for the pixel marked with red. (a) ASPP: The context is a set of sparsely sampled pixels marked with orange, blue. The pixels with different colors correspond to different dilation rates. Those pixels are distributed in both the object region and the background region. (b) Our OCR: The context is expected to be a set of pixels lying in the object (marked with color blue). The image is chosen from ADE20K.




图 7: OCR 网络结构图

粉色的框通过分支监督训练获取一种粗分类结果，用于后续的目标区域特征表示基于目标上下文表示来增强每个像素的特征表示，大致结构如下：




Fig. 4: **Segmentation transformer.** Rephrasing the OCR pipeline showing in Figure 3 using the Transformer encoder-decoder architecture. The encoder self-attention unit in the gray box could be a local version and is optional and is useful for boosting the image features. The decoder self-attention unit serves as the role of interacting the category queries and can be discarded for a single decoder layer or moved after the decoder cross-attention unit.

4.5 SETR

由于注意力机制的次幂复杂度，feature maps 的分辨率越高所需的计算量就越大，因此这些方法都是将注意力机制放在分辨率较小的深层后面，以利用其小尺寸的输入来降低计算复杂度。这就意味着，缺失了浅层注意力依赖关系。




Figure 1. Schematic illustration of the proposed *Segmentation Transformer (SETR)* (a). We first split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. To perform pixel-wise segmentation, we introduce different decoder designs: (b) progressive upsampling (resulting in a variant called *SETR-PUP*); and (c) multi-level feature aggregation (a variant called *SETR-MLA*).

图 8: SERT 网络结构图

4.5.1 Decoder 设计

- 朴素上采样 (Naive): 将 Transformer 结果投影到类别个数的维度上后, 直接双线性上采样
- 渐进上采样 (PUP): 【直接上采样可能会引入噪声】, 因此会通过多次上采样来恢复原有的维度
- 多级特征融合 (MLA): 【与特征金字塔相似】

4.6 Mask2Former






Figure 2. **Mask2Former overview.** Mask2Former adopts the same meta architecture as MaskFormer [14] with a backbone, a pixel decoder and a Transformer decoder. We propose a new Transformer decoder with *masked attention* instead of the standard cross-attention (Section 3.2.1). To deal with small objects, we propose an efficient way of utilizing high-resolution features from a pixel decoder by feeding one scale of the multi-scale feature to one Transformer decoder layer at a time (Section 3.2.2). In addition, we switch the order of self and cross-attention (*i.e.*, our masked attention), make query features learnable, and remove dropout to make computation more effective (Section 3.2.3). Note that positional embeddings and predictions from intermediate Transformer decoder layers are omitted in this figure for readability.

4.7 Swin Transformer

用 Transformer 没毛病，可以用到不同的任务。解决目前存在两个挑战：

- 目标尺寸多样化 【解决方案有：目标检测中的 FPN、分割任务中的 skip connection】
- 图片分辨率大，计算量大 【解决方案有：使用后续的特征图、分 patch】



移动窗口的层级式注意力机制：画窗口，并只在窗口内做注意力【利用了局部性相似的先验条件】

主体结构如下：





Figure 3. (a) The architecture of a Swin Transformer (Swin-T); (b) two successive Swin Transformer Blocks (notation presented with Eq. (3)). W-MSA and SW-MSA are multi-head self attention modules with regular and shifted windowing configurations, respectively.

4.7.1 Patch Merging

目的是实现类池化操作




4.7.2 Shifted window

为了更好的理解上下文，移动窗口，完成交互，实现局部注意力到全局注意力

提醒： 使用滑动窗口的方式和不适用滑动窗口的方式，计算复杂度对比

Transformer (Swin-T), (b) two successive Swin Transformer blocks (notation presented with head self attention modules with regular and shifted windowing configurations, respectively.

s as those of typical
[2] and ResNet [30].
can conveniently re-
g methods for vari-



uilt by
(MSA)

on an image of $h \times w$ patches are³:

$$\begin{aligned} \Omega(\text{MSA}) &= 4hwC^2 + 2(hw)^2C, \\ \Omega(\text{W-MSA}) &= 4hwC^2 + 2M^2hwC, \end{aligned} \quad \begin{aligned} (1) \\ (2) \end{aligned}$$

where the former is quadratic to patch number hw , and the latter is linear when M is fixed (set to 7 by default). Global self-attention computation is generally unaffordable for a large hw , while the window based self-attention is scalable.

图 9: 公式 (1) 为常规注意力机制，公式 (2) 为滑动窗口注意力机制。其中， hw 表示 patch 的数量， M 为每个 patch 的大小（默认为 7）

为了完成跨窗口交互，且不增加计算量【CNN 里面通过 padding 实现】，Swin 通过平移变换实现





Figure 4. Illustration of an efficient batch computation approach for self-attention in shifted window partitioning.

提醒： 如何实现 Masked MSA

在不需要的位置加上一个大的负数，后面再通过 softmax 变换为 0

**4.7.3 Swin Transformer Block**

BBlock 内部的结构数量都是 $\times 2$ ，是因为需要先完成一次窗口内部自注意力，还有一次窗口交互自注意力

$$\begin{aligned}
 \hat{\mathbf{z}}^l &= \text{W-MSA}(\text{LN}(\mathbf{z}^{l-1})) + \mathbf{z}^{l-1}, \\
 \mathbf{z}^l &= \text{MLP}(\text{LN}(\hat{\mathbf{z}}^l)) + \hat{\mathbf{z}}^l, \\
 \hat{\mathbf{z}}^{l+1} &= \text{SW-MSA}(\text{LN}(\mathbf{z}^l)) + \mathbf{z}^l, \\
 \mathbf{z}^{l+1} &= \text{MLP}(\text{LN}(\hat{\mathbf{z}}^{l+1})) + \hat{\mathbf{z}}^{l+1},
 \end{aligned} \tag{3}$$

where $\hat{\mathbf{z}}^l$ and $\mathbf{z}^l$ denote the output features of the (S)W-MSA module and the MLP module for block l , respectively;

4.7.4 消融实验

(a) Various frameworks							
Method	Backbone	AP ^{box}	AP ₅₀ ^{box}	AP ₇₅ ^{box}	#param.	FLOPs	FPS
Cascade	R-50	46.3	64.3	50.5	82M	739G	18.0
Mask R-CNN	Swin-T	50.5	69.3	54.9	86M	745G	15.3
ATSS	R-50	43.5	61.9	47.0	32M	205G	28.3
	Swin-T	47.2	66.5	51.3	36M	215G	22.3
RepPointsV2	R-50	46.5	64.6	50.3	42M	274G	13.6
	Swin-T	50.0	68.5	54.2	45M	283G	12.0
Sparse R-CNN	R-50	44.5	63.4	48.2	106M	166G	21.0
	Swin-T	47.9	67.3	52.3	110M	172G	18.4

图 10: 使用 Swin Transformer 作为 Backbone，模型参数量、耗时略大，但效果明显

	ImageNet		COCO		ADE20k
	top-1	top-5	AP ^{box}	AP ^{mask}	mIoU
w/o shifting	80.2	95.1	47.7	41.5	43.3
shifted windows	81.3	95.6	50.5	43.7	46.1
no pos.	80.1	94.9	49.2	42.6	43.8
abs. pos.	80.5	95.2	49.0	42.4	43.2
abs.+rel. pos.	81.3	95.6	50.2	43.4	44.0
rel. pos. w/o app.	79.3	94.7	48.2	41.9	44.1
rel. pos.	81.3	95.6	50.5	43.7	46.1

Table 4. Ablation study on the *shifted windows* approach and different position embedding methods on three benchmarks, using the Swin-T architecture. w/o shifting: all self-attention modules adopt regular window partitioning, without *shifting*; abs. pos.: absolute position embedding term of ViT; rel. pos.: the default settings with an additional relative position bias term (see Eq. (4)); app.: the first scaled dot-product term in Eq. (4).

在分类任务中, shifting 和位置编码, 提升不明显, 显著的提升主要体现在下游任务中, 比如语义分割、目标检测等等

4.7.5 Patch Diversification




Figure 1: (a) An overview of vision transformers by following (Dosovitskiy et al., 2020). Each image patch is first transformed to a latent representation using a linear patch projection layer. The *dog* image is from ImageNet (Deng et al., 2009). (b) Comparisons of patch-wise absolute cosine similarities. All similarities are computed with 10,000 sub-sampled images from the ImageNet training set without data augmentation.

背景: 提取每个 self-attention 层的 patch 表示, 并计算 patch 表示之间的平均绝对余弦相似性。发现 patch 表示之间的相似性显著增加

结论: self-attention 倾向于将不同的 patch 映射 × 相似的潜在表示, 从而导致信息丢失和性能下降

措施:

- Patch-wise cosine loss: 通过惩罚 patch-wise 余弦相似性来直接提高不同 patch 表示之间的多样性
- Patch-wise contrastive loss: 基于 patch 的对比损失, 鼓励第一层和后续层之间学习的相对应 patch 之间的表示相似, 不对应的 patch 之间的表示不同【因为第一个 self-attention 层的输入 patch 表示只依赖于输入像素, 因此往往更加多样化】

- Patch-wise mixing loss: 迫使 self-attention 层只关注与自己类别相关的 patch

4.8 SwinV2




Figure 1. To better scale up model capacity and window resolution, several adaptations are made on the original Swin Transformer architecture (V1): 1) A *res-post-norm* to replace the previous *pre-norm* configuration; 2) A *scaled cosine attention* to replace the original *dot product attention*; 3) A *log-spaced continuous relative position bias* approach to replace the previous *parameterized* approach. Adaptions 1) and 2) make it easier for the model to scale up capacity. Adaption 3) makes the model to be transferred more effectively across window resolutions. The adapted architecture is named Swin Transformer V2.

创新点:

- res-post-norm & cosine attention: 提高大模型的训练稳定性和准确性
- Log-CPB: 允许模型在不同窗口大小之间自由转移, 解决高低分辨率任务之间的迁移问题
- SimMIM: 自监督学习

4.9 BeiT

在此之前,

通过将图像分辨率降低来实现 Transformer 在 CV 的应用, 会丢失很多图像信息。而基于像素级别的回归方法存在过度学习小范围细节信息, 导致在整体结构上学习能力不足

图像无监督预训练, 利用 BERT 中 MLM (Masked Language Modeling) 的思路, 将一个图像转化成 token 序列, 对图像 token 进行 mask, 然后预测被 mask 掉的图像 token, 实现图像领域的无监督预训练




Figure 1: Overview of BEiT pre-training. Before pre-training, we learn an “image tokenizer” via autoencoding-style reconstruction, where an image is tokenized into discrete visual tokens according to the learned vocabulary. During pre-training, each image has two views, i.e., image patches, and visual tokens. We randomly mask some proportion of image patches (gray patches in the figure) and replace them with a special mask embedding [M]. Then the patches are fed to a backbone vision Transformer. The pre-training task aims at predicting the visual tokens of the *original* image based on the encoding vectors of the *corrupted* image.

生成预测的 visual tokens 是目标。训练的时候, 优化步骤是先优化 dVAE (重构损失), 通过优化 Tokenizer 和 Decoder 让 dVAE 能够学习到更好的隐变量又能更好还原原图, 然后再优化 Encoder 和 Masked Image Modeling Head, 使其能更好预测出对应的 visual tokens

$$\sum_{(x_i, \tilde{x}_i) \in \mathcal{D}} \left(\underbrace{\mathbf{E}_{z_i \sim q_\phi(z|x_i)} [\log p_\psi(x_i|z_i)]}_{\text{Stage1: Visual Token Reconstruction}} + \underbrace{\log p_\sigma(\hat{z}_i|\tilde{x}_i)}_{\text{Stage2: Mask Modeling Image}} \right) \quad (6)$$

4.9.1 Blockwise mask

掩码策略不是完全随机的, 而是按照 block 进行掩码, 掩码率为 40%

Algorithm 1 Blockwise Masking

Input: $N(=h \times w)$ image patches

Output: Masked positions $\mathcal{M}$

$\mathcal{M} \leftarrow \{\}$

repeat

$s \leftarrow \text{Rand}(16, 0.4N - |\mathcal{M}|)$ $\triangleright$ Block size

$r \leftarrow \text{Rand}(0.3, \frac{1}{0.3})$ $\triangleright$ Aspect ratio of block

$a \leftarrow \sqrt{s \cdot r}; b \leftarrow \sqrt{s/r}$

$t \leftarrow \text{Rand}(0, h - a); l \leftarrow \text{Rand}(0, w - b)$

$\mathcal{M} \leftarrow \mathcal{M} \cup \{(i, j) : i \in [t, t + a), j \in [l, l + b)\}$

until $|\mathcal{M}| > 0.4N$ $\triangleright$ Masking ratio is 40%

return $\mathcal{M}$

4.9.2 MASK AutoEncoder, MAE

创新点：非对称的编码器-解码器架构和高掩码率

将图像中的某些图像块掩码掉，然后要求模型重构出掩码掉的像素。




Figure 1. **Our MAE architecture.** During pre-training, a large random subset of image patches (e.g., 75%) is masked out. The encoder is applied to the small subset of *visible patches*. Mask tokens are introduced *after* the encoder, and the full set of encoded patches and mask tokens is processed by a small decoder that reconstructs the original image in pixels. After pre-training, the decoder is discarded and the encoder is applied to uncorrupted images (full sets of patches) for recognition tasks.

4.10 BeiTV2

当时已有的 MIM 方法有三种：原始像素、手工特征和视觉 tokens




Figure 2: Pipeline for visual tokenizer training. After training, each image is converted to discrete visual tokens.

BeiTV2 有两个主要的创新

4.10.1 向量化知识蒸馏, VQ-KD

VQ: encoder 将图像映射为一串视觉 token, quantizer 通过最近邻的方式从码本 $\mathcal{V}$ ($\mathcal{V} \in \mathbb{R}^{K \times D}$) 中查找与每个 token 的 L2 距离最接近的 embedding

KD: 在得到量化后的视觉 token 之后, 将其送入解码器, 解码器的输出目标是教师模型 (如 CLIP、DINO 等) 给出的语义特征【最大化解码器的输出与教师模型语义特征的余弦相似度】

提醒: 为什么不直接使用特征表示, 而是在码本中找最接近的嵌入向量?

4.10.2 块聚合




Figure 3: The MIM framework equipped with patch aggregation. The pretraining loss is the summation of $\mathcal{L}_{MIM}$ and $\mathcal{L}_{MIM}^c$. The loss term $\mathcal{L}_{MIM}^c$ explicitly encourages the [CLS] token to aggregate patch information to global representations.

原始的 BEiT4.9 只有 patch-level 的 MIM 任务, 但是并没有预训练 CLS token, 【即没有预训练全局的图像特征】。而 BEiT v2 设计了一种 bottleneck 结构来实现对 CLS token 的预训练。这里除了常规的 MIM 损失, 还增加了 CLS token 的 MIM 损失, 具体地,

- 从 ViT 的某个中间层 (第 l 层) 取出 patch 的特征然后和最后的 CLS token 重新组合在一起
- 额外增加一个两层的 decoder 来进行 MIM 建模

由于只有 CLS token 连接了第 $l+1$ 层之后的 ViT block, 所以附属的 MIM 任务将强制让 CLS token 学习到全局图像特征来实现 MIM 损失最小化。由于预训练了 CLS token, 所以在迁移到下游分类任务时, 也用 CLS token 来进行全局特征提取。

5 半监督学习

提醒:

- 定义：半监督学习（Semi-Supervised Learning, SSL）属于弱监督学习的一个分支，具体地：弱监督学习可以分为三类：
 - 不完全监督【只有很小的子集有标签】，包含两个方向：
 - * 主动学习
 - * 半监督学习，按学习方式可分为纯半监督学习和直推学习
 - 不确切监督【只有粗粒度标签】
 - 不准确监督【标签不总是真实】
- 基本假设：未标记数据必须是有意义的，具有潜在价值的样本，而非无用的噪声样本
- 存在的问题：
 - 无效标签样本的有效利用问题
 - 大量无效标签样本的高效使用问题
 - 很多半监督算法都有无监督的影子，因此对于特征的选择非常的敏感

半监督语义分割方法大致可以分为 5 类：

- 类似于 GAN 结构生成对抗
- 一致性正则化【最小化同一图像的不同预测之间的差异】
- 伪标记方法
 - 自训练方法【依赖于现有模型的泛化性，缺乏检测自身错误的机制，同时需要解决伪标签中的类不平衡问题】
 - 互训练方法【基于分歧的策略】
- 基于对比学习
- 混合模式

5.1 Mean Teacher

核心思想是强制学生网络和教师网络的预测在存在扰动的情况下一致，其中教师网络的权重是通过学生网络权重的指数移动平均值（EMA）计算得出的。

扰动的方式有四种：

- 基于输入的扰动：CutOut、CutMix、ClassMix、Complex、其他方法
- 基于特征的扰动：交叉一致性训练（CCT）

- 基于网络的扰动，比如使用不同的起始权重
- 混合模式